Tarea 07. Selección de Atributos - Score de Fisher

1st Jayson Chico Vargas
Universidad Autónoma de Baja California
Mexicali, Baja California
jayson.chico@uabc.edu.mx

***Resumen*—Este documento describe el desarrollo y análisis de una aplicación interactiva en MATLAB. El sistema procesa conjuntos de datos con múltiples variables y dos clases. A través de la interfaz gráfica, se calculan y visualizan la distancia entre medias y la suma de varianzas, generando un ranking preciso. El software despliega un diagrama de barras con las puntuaciones F-Score y permite proyectar interactivamente las clases en un espacio euclidiano tridimensional, demostrando empíricamente cómo los atributos con mayor Fisher Score logran una separación geométrica óptima de las clases.**

***Index Terms*—Selección de Atributos, Fisher Score, Minería de Datos, Reducción de Dimensionalidad, MATLAB, Espacio Euclidiano, Filtro.**

I. Introducción

En el ámbito de la Minería de Datos y el Aprendizaje Automático, trabajar con conjuntos de datos de alta dimensionalidad presenta retos significativos, como el aumento del costo computacional y la susceptibilidad al sobreajuste (la "maldición de la dimensionalidad"). La selección de características (*Feature Selection*) es una fase crítica del preprocesamiento que busca identificar los atributos más relevantes. Dentro de estas técnicas, los métodos de Filtro son altamente valorados por su eficiencia, ya que evalúan las propiedades intrínsecas de los datos independientemente de cualquier algoritmo de clasificación posterior.

I-A. ¿Qué es la técnica, método o algoritmo?

La práctica se centra en el **Fisher Score**, una métrica de evaluación supervisada utilizada en los métodos de filtro. La intuición geométrica y estadística del Fisher Score es directa: una característica es excelente para clasificar si, al proyectar los datos sobre ella, las distintas clases están lo más separadas posible entre sí (gran distancia entre sus medias) y, al mismo tiempo, los datos de una misma clase están lo más agrupados posible (pequeña varianza intra-clase).

I-B. ¿Quién la inventó, dónde y para qué?

El fundamento matemático del Fisher Score proviene del trabajo del estadístico y biólogo británico **Sir Ronald Aylmer Fisher** en 1936. Fisher lo desarrolló originalmente en la Universidad de Londres para la taxonomía botánica, creando el análisis discriminante lineal para distinguir entre especies de flores de Iris basándose en medidas de sus pétalos y sépalos. Hoy en día, su principio es una piedra angular en el reconocimiento de patrones y el análisis de datos multidimensionales.

I-C. Ecuaciones y Algoritmos

El cálculo del Fisher Score para una característica específica i, en un problema de dos clases (Clase 1 y Clase 2), se divide en tres componentes principales:

1. Distancia entre las medias (D_i): Mide qué tan separados están los centroides de ambas clases para el atributo i. Se eleva al cuadrado para evitar valores negativos.

$$D_i = (\mu_{1i} - \mu_{2i})^2$$

2. Suma de Varianzas (S_i): Mide la dispersión interna de los datos dentro de cada clase.

$$S_i = \sigma_{1i}^2 + \sigma_{2i}^2$$

3. Fisher Score (F_i): Es la razón entre la distancia de las medias y la dispersión. Un valor F_i alto indica un alto poder discriminativo.

$$F_i = \frac{D_i}{S_i}$$

I-D. Aplicaciones, Ventajas y Desventajas

Aplicaciones: Es ampliamente utilizado en bioinformática (selección de genes relevantes en microarreglos de ADN), procesamiento de imágenes (selección de descriptores visuales), y detección de spam, donde los datasets suelen tener miles de atributos.

Ventajas:

- Es un método extremadamente rápido y computacionalmente ligero, ideal para *datasets* masivos.
- Al ser un método de Filtro, es agnóstico; las características seleccionadas servirán para casi cualquier modelo predictivo (SVM, Redes Neuronales, Árboles).

Desventajas (Análisis Crítico):

- *Ignora la correlación:* El Fisher Score evalúa cada atributo de manera individual. Puede seleccionar tres atributos con un *score* altísimo, pero que en realidad aportan exactamente la misma información (son redundantes entre sí).
- No detecta dependencias complejas donde dos variables, siendo inútiles por sí solas, son excelentes predictores al usarse juntas.

II. Configuración Experimental

Para el desarrollo de esta herramienta, se utilizó el siguiente entorno:

- **Software:** MATLAB (App Designer) ejecutándose bajo el sistema operativo Windows.

- **Estructura de Datos:** Se utilizaron archivos en formato `.mat` (`datos_wdbc`, `Data_Synthetic_1000x50x2C`, etc.).
- **Interfaz Gráfica:** Se implementó un panel interactivo que incluye:
  - Un `TextArea` con fuente monoespaciada para presentar el ranking tabular exacto (Mostrando ID, D^2, S y F-Score a 6 decimales).
  - Un gráfico `UIAxes2` configurado como diagrama de barras para mostrar visualmente el F-Score de cada atributo, incluyendo de forma dinámica el total de atributos y sus valores Máximo y Mínimo.
  - Un gráfico `UIAxes` tridimensional que permite graficar la dispersión de puntos en un espacio euclidiano seleccionando cualquier combinación de ejes (X, Y, Z) mediante *Callbacks* en menús desplegables.

III. Resultados y Discusión

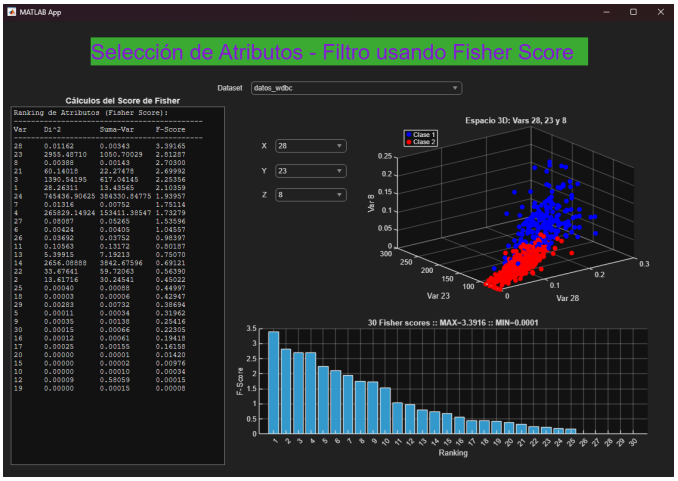

Figura 1. Diagramas del primer dataset

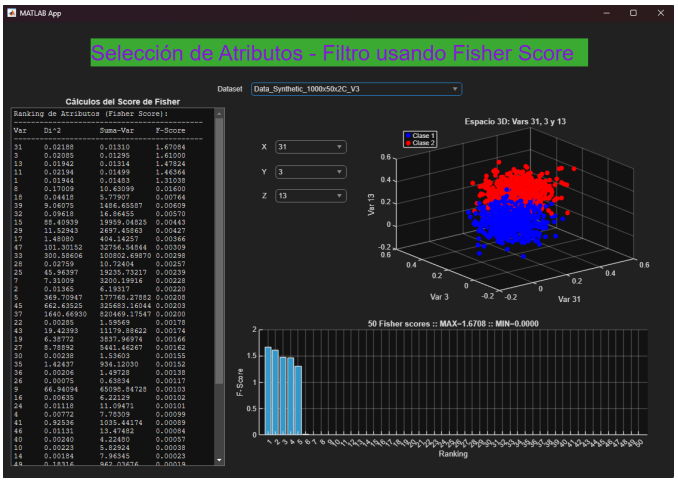

Figura 2. Diagramas del segundo dataset

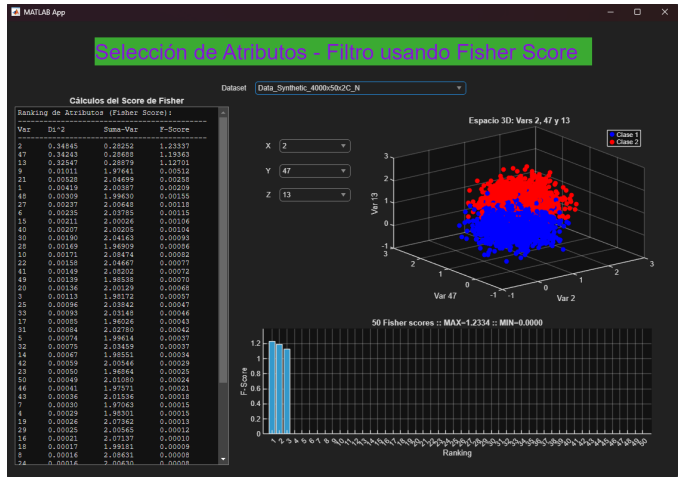

Figura 3. Diagramas del tercer dataset

Durante la ejecución, el algoritmo procesó eficazmente datasets de hasta 4000 instancias y 50 variables. El reporte tabular generó un ranking preciso donde se evidenció que variables con gran distancia entre medias y baja dispersión obtuvieron F-Scores superiores a 3.0.

Al visualizar los resultados en el espacio 3D, se comprobó la validez del método matemático: cuando se seleccionaron las variables "Top 3"del ranking (por ejemplo, Vars 28, 23 y 8), las clases roja y azul formaron clústeres geométricamente distinguibles. En contraste, al forzar la visualización de variables con un Fisher Score cercano a cero, la gráfica 3D mostró una nube de puntos completamente mezclada y solapada, confirmando la inutilidad de dichas variables para propósitos de clasificación.

IV. Prompts Utilizados

Para la investigación teórica, formulación matemática y comprensión del comportamiento de los algoritmos de reducción de dimensionalidad, se utilizó el asistente de IA *Gemini* mediante los siguientes *prompts* de consulta:

1. *"Actúa como un experto en minería de datos y aprendizaje automático. Explica de manera formal qué es la selección de atributos mediante el método de Filtro. ¿Cuáles son las ventajas y desventajas analíticas de utilizar el Fisher Score frente a métodos de tipo Wrapper al procesar conjuntos de datos de alta dimensionalidad?"*
2. *"Proporciona ejemplos de aplicaciones reales de la reducción de dimensionalidad guiada por Fisher Score en la industria moderna, específicamente en el ámbito de la bioinformática (análisis de microarreglos) y el reconocimiento de patrones visuales."*
3. *"¿Cuál es el origen histórico del estadístico de Fisher, quién lo inventó originalmente y matemáticamente cómo se relaciona la distancia entre las medias y la dispersión intra-clase para determinar el poder discriminativo de un atributo?"*

REFERENCIAS

[1] GeeksforGeeks, "Fisher Score for Feature Selection," *Machine Learning Tutorial*. [En línea]. Disponible en: https://www.geeksforgeeks.org/machine-learning/fisher-score-for-feature-selection/

[2] KDnuggets, "Advanced Feature Selection Techniques for Machine Learning Models," *Data Science Blog*. [En línea]. Disponible en: https://www.kdnuggets.com/2023/06/advanced-feature-selection-techniques-machine-learning-models.html

[3] IBM, "What is feature selection?," *IBM Think Topics*. [En línea]. Disponible en: https://www.ibm.com/think/topics/feature-selection

[4] D. Sánchez Martín, "Memoria de Trabajo de Fin de Máster (TFM)," *Repositorio Documental Gredos, Universidad de Salamanca*. [En línea]. Disponible en: https://gredos.usal.es/bitstream/handle/10366/164911/memoria_TFM_diego_sanchez_martin.pdf?sequence=1&isAllowed=y