Tarea 08. Algoritmo K-Means

1st Jayson Chico Vargas
Universidad Autónoma de Baja California
Mexicali, Baja California
jayson.chico@uabc.edu.mx

***Resumen*—Este documento describe el desarrollo y análisis de una aplicación interactiva en MATLAB para la implementación del algoritmo de agrupamiento K-Means. El sistema permite procesar conjuntos de datos bidimensionales mediante un proceso iterativo de optimización de centroides. A través de la interfaz gráfica, se controlan parámetros críticos como el número de grupos (K), el criterio de parada (Theta) y la métrica de tendencia central (Media o Mediana). El software visualiza dinámicamente el rastro de los centroides y genera una curva de convergencia del error, permitiendo observar cómo el algoritmo minimiza la distancia intra-clúster hasta alcanzar la estabilidad numérica.**

***Index Terms*—Clustering, K-Means, Aprendizaje No Supervisado, MATLAB, Convergencia, Centroides, Optimización.**

I. Introducción

En el ámbito de la Minería de Datos, el aprendizaje no supervisado es fundamental para descubrir patrones en datos que carecen de etiquetas previas. A diferencia de los métodos de clasificación supervisada, los algoritmos de *clustering* buscan agrupar objetos similares basándose únicamente en sus características intrínsecas y proximidad geométrica.

I-A. ¿Qué es la técnica, método o algoritmo?

El algoritmo K-Means es un método de agrupamiento que particiona n observaciones en k grupos. El objetivo es minimizar la suma de los cuadrados de las distancias entre cada dato y el centroide de su grupo asignado. Es un proceso heurístico que alterna entre asignar puntos al centro más cercano y actualizar la posición de dicho centro.

I-B. ¿Quién la inventó, dónde y para qué?

El término fue acuñado por **James MacQueen** en 1967, aunque la idea técnica fue propuesta originalmente por **Stuart Lloyd** en 1957 en los Laboratorios Bell como una técnica para la modulación por impulsos codificados (PCM). Su propósito original era la cuantización de señales, convirtiéndose hoy en una herramienta estándar para la segmentación y análisis de datos.

I-C. Ecuaciones y Algoritmos

El algoritmo busca minimizar la función objetivo de error cuadrático J:

$$J = \sum_{j=1}^{k} \sum_{i \in C_j} ||x_i - c_j||^2 \tag{1}$$

El proceso implementado en el software sigue estos pasos:

1. **Asignación:** Se calcula la distancia euclidiana entre cada punto y los centroides. El punto se une al grupo con la distancia mínima.
2. **Actualización:** Se recalcula el centroide usando la **Media** o la **Mediana**, según la elección del usuario.
3. **Convergencia:** El ciclo se repite hasta que el cambio en la posición de los centroides es menor a un umbral θ: $||c_t - c_{t-1}|| < \theta$.

II. Configuración Experimental

Para el desarrollo de esta herramienta, se utilizó el siguiente entorno:

- **Software:** MATLAB (App Designer).
- **Datasets:** Archivos `.mat` (`datos_clustering.mat`, `kmeansdata02.mat`).
- **Interfaz Gráfica:** Se implementó un panel interactivo que incluye:
  - `TextArea` monoespaciado para la tabla de coordenadas por iteración.
  - `UIAxes` para visualizar los datos, los centroides (círculos de colores) y el rastro de su movimiento (líneas negras).
  - `UIAxes2` para la gráfica de convergencia (Magnitud del cambio vs Iteración).

III. Resultados y Discusión

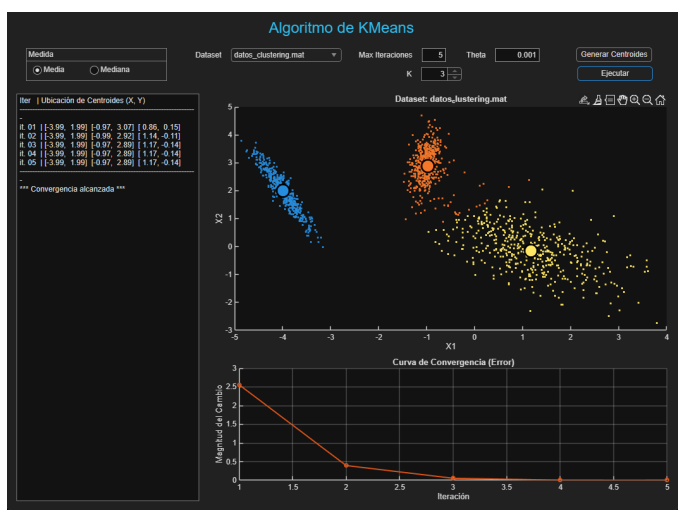

Figura 2. Ejecución del algoritmo con dataset kmeansdata02.mat

Durante las pruebas, el algoritmo demostró una convergencia estable. Al visualizar el rastro en el `UIAxes`, se comprobó cómo los centroides se desplazan desde sus posiciones iniciales aleatorias hacia los centros de masa de los datos. La curva de convergencia en `UIAxes2` validó el proceso, mostrando un descenso drástico en las primeras iteraciones hasta estabilizarse por debajo del umbral $\theta = 0{,}001$.

IV. Prompts Utilizados

1. *"¿Quién invento el algoritmo?"*
2. *"Explica la lógica para graficar el rastro de trayectoria de un punto en MATLAB sin borrar la posición anterior."*
3. *"¿Cuál es el significado matemático de la convergencia basada en una tolerancia Theta en algoritmos iterativos?"*

Referencias

[1] IBM, "¿Qué es el clustering de k-means?", *IBM Think Topics*. [En línea]. Disponible en: https://www.ibm.com/mx-es/think/topics/k-means-clustering

[2] IEBS School, "Algoritmo K-means: qué es y cómo funciona en Big Data", *IEBS Digital School Hub*. [En línea]. Disponible en: https://www.iebschool.com/hub/algoritmo-k-means-que-es-y-como-funciona-big-data/

[3] A. Fernández, "¿Qué es y cómo programar el algoritmo K-means desde 0?", *Blog de Datos y Programación*. [En línea]. Disponible en: https://anderfernandez.com/blog/que-es-y-como-programar-el-algoritmo-k-means-en-r-desde-0/